

Aufgabe 37 γ -Astronomie 2

Bei dieser Aufgabe handelt es sich um eine Fortführung der Aufgabe γ -Astronomie vom letzten Blatt. Jetzt soll festgestellt werden ob sich an der Position, auf die das Teleskop gerichtet war, wirklich eine γ -Quelle befindet. Hierzu wird die Nullhypothese verwendet. Zur Erinnerung die Likelihoodfunktion lautete

$$\ln L = -F = N_{\text{off}} \ln(b) + N_{\text{on}} \ln(s + \alpha b) - (1 + \alpha)b - s - \ln(N_{\text{off}}!) - \ln(N_{\text{on}}!) \quad (1)$$

und folgende Werte für s und b machten diese Likelihood maximal:

$$\hat{s} = N_{\text{on}} - \alpha N_{\text{off}} \quad (2)$$

$$\hat{b} = N_{\text{off}} \quad (3)$$

- (a) Die Nullhypothese besagt, dass es gar keine γ -Quelle gibt, also $s_0 = 0$. Welcher Wert und welcher Fehler ergeben sich unter dieser Annahme für b_0 nach der Methode der maximalen Likelihood?

Likelihood: $\propto = \frac{t_{\text{on}}}{t_{\text{off}}}$

$$F(s, b | N_{\text{on}}, N_{\text{off}}) = -N_{\text{off}} (\ln(b) - N_{\text{on}} \ln(s + \alpha b) + (1 + \alpha)b + s + \ln(N_{\text{off}}!) + \ln(N_{\text{on}}!))$$

Nullhypothese: $s_0 = 0$

Welches b_0 ergibt sich dafür?

Gesucht ist das Maximum von $-F$ wenn $s_0 = 0$

$$\frac{\partial F}{\partial b} = -\frac{N_{\text{off}}}{b} - \frac{N_{\text{on}}}{b} + (1 + \alpha) \stackrel{!}{=} 0$$

$$\Rightarrow \hat{b}_0 = \frac{N_{\text{off}} + N_{\text{on}}}{1 + \alpha}$$

Variante:

$$\frac{d^2 F}{db^2} = +\frac{N_{\text{off}}}{b^2} + \frac{N_{\text{on}}}{b^2} = +\frac{1}{b^2} (N_{\text{off}} + N_{\text{on}})$$

$$\text{Var}(\hat{b}_0) = \left(\frac{1}{\frac{d^2 F}{db^2} \hat{b}_0} \right) = +\hat{b}_0^2 (N_{\text{off}} + N_{\text{on}})^{-1}$$

$$= \left(\frac{N_{\text{off}} + N_{\text{on}}}{1 + \alpha} \right)^2 (N_{\text{off}} + N_{\text{on}})^{-1}$$

$$\text{Var}(\hat{b}_0) = \frac{N_{\text{off}} + N_{\text{on}}}{(1 + \alpha)^2}$$

$$\sigma = \sqrt{\text{Var}(\hat{b}_0)} = \sqrt{\frac{N_{\text{off}} + N_{\text{on}}}{1 + \alpha}}$$

- (b) Wie lautet das Verhältnis λ der beiden Likelihoods?

Likelihood:

$$\text{Likelihood} = \text{max}(-F / \ln(N_{\text{off}}))$$

Likelihood:

$$\begin{aligned}
 L(s, b | N_{\text{on}}, N_{\text{off}}) &= \exp(-F(s, b | N_{\text{on}}, N_{\text{off}})) \\
 &= \exp(-(N_{\text{off}} \ln(b) + N_{\text{on}} \ln(s + \alpha b) - (1+\alpha)b - s - (\ln(N_{\text{off}}!) - \ln(N_{\text{on}}!))) \\
 &= b^{N_{\text{off}}} \cdot (s + \alpha b)^{N_{\text{on}}} \cdot \exp(-(1+\alpha)b - s) \cdot \frac{1}{N_{\text{off}}!} \cdot \frac{1}{N_{\text{on}}!}
 \end{aligned}$$

$$\lambda = \frac{L(s_0, \hat{b}_0 | N_{\text{off}}, N_{\text{on}})}{L(\hat{s}, \hat{b} | N_{\text{off}}, N_{\text{on}})} \quad \text{mit} \quad \hat{s} = N_{\text{on}} - \alpha N_{\text{off}} \quad s_0 = 0 \\
 \hat{b} = N_{\text{off}} \quad \hat{b}_0 = \frac{N_{\text{off}} + N_{\text{on}}}{1+\alpha}$$

$$\begin{aligned}
 \lambda &= \frac{\hat{b}_0^{N_{\text{off}}} \cdot (\hat{s}_0 + \alpha \hat{b}_0)^{N_{\text{on}}} \cdot \exp(-(1+\alpha)\hat{b}_0 - \hat{s}_0) \cdot \frac{1}{N_{\text{off}}!} \cdot \frac{1}{N_{\text{on}}!}}{\hat{b}^{N_{\text{off}}} \cdot (\hat{s} + \alpha \hat{b})^{N_{\text{on}}} \cdot \exp(-(1+\alpha)\hat{b} - \hat{s}) \cdot \frac{1}{N_{\text{off}}!} \cdot \frac{1}{N_{\text{on}}!}} \\
 &= \frac{\left(\frac{N_{\text{off}} + N_{\text{on}}}{1+\alpha}\right)^{N_{\text{off}}} \cdot \left(\alpha \frac{N_{\text{off}} + N_{\text{on}}}{1+\alpha}\right)^{N_{\text{on}}} \exp(-(1+\alpha)\left(\frac{N_{\text{off}} + N_{\text{on}}}{1+\alpha}\right))}{N_{\text{off}}^{N_{\text{off}}} \cdot N_{\text{on}}^{N_{\text{on}}} \exp(-(N_{\text{off}} + N_{\text{on}}))} \\
 &= \frac{\left(\frac{N_{\text{off}} + N_{\text{on}}}{1+\alpha}\right)^{N_{\text{off}}} \cdot \left(\alpha \frac{N_{\text{off}} + N_{\text{on}}}{1+\alpha}\right)^{N_{\text{on}}} \exp(-(N_{\text{off}} + N_{\text{on}}))}{N_{\text{off}}^{N_{\text{off}}} \cdot N_{\text{on}}^{N_{\text{on}}} \exp(-(N_{\text{off}} + N_{\text{on}}))}
 \end{aligned}$$

$$\lambda = \frac{\left(\frac{N_{\text{off}} + N_{\text{on}}}{N_{\text{off}} \cdot N_{\text{on}}}\right)^{N_{\text{off}} + N_{\text{on}}}}{(1+\alpha)^{N_{\text{off}} + N_{\text{on}}}}$$

- (c) Unter den gegebenen Hypothesen und mit großen $N_{\text{on}}, N_{\text{off}}$ ist $D = -2 \ln \lambda$ χ^2 -verteilt mit einem Freiheitsgrad. Mit welcher Konfidenz lehnen Sie die Nullhypothese ab? Geben Sie Ihr Ergebnis in Einheiten von Sigma an.

Tipp: Betrachten Sie eine standardnormalverteilte Variable u . Welcher Verteilung folgt u^2 ? Vergleichen Sie mit D .

$D = -2 \ln(\lambda)$ ist χ^2 verteilt mit einem Freiheitsgrad

$$\begin{aligned}
 D &= -2 \ln\left(\frac{\left(\frac{N_{\text{off}} + N_{\text{on}}}{N_{\text{off}} \cdot N_{\text{on}}}\right)^{N_{\text{off}} + N_{\text{on}}}}{(1+\alpha)^{N_{\text{off}} + N_{\text{on}}}}\right) \\
 &= -2 \left[(N_{\text{off}} + N_{\text{on}}) \ln(N_{\text{off}} + N_{\text{on}}) - N_{\text{off}} \ln(N_{\text{off}}) - N_{\text{on}} \ln(N_{\text{on}}) + N_{\text{on}} \ln(\alpha) - (N_{\text{off}} + N_{\text{on}}) \ln(1+\alpha) \right]
 \end{aligned}$$

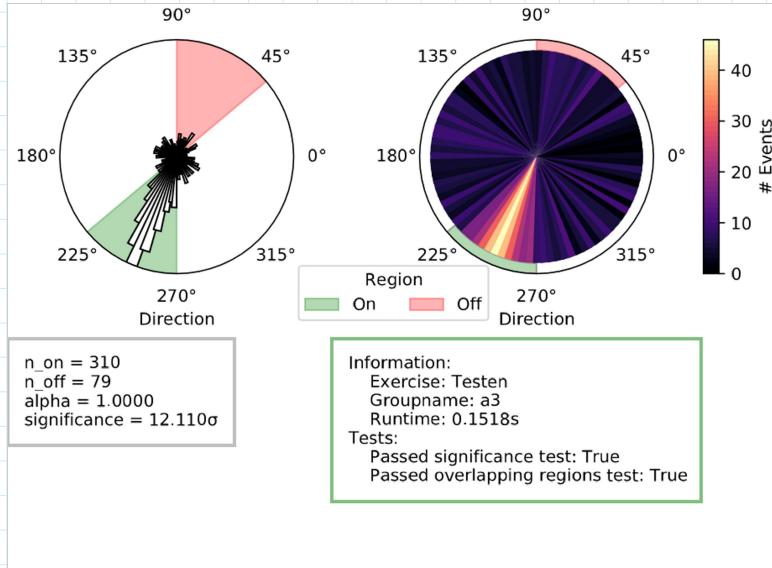
... (keine Ahnung)

Signifikanz: $\alpha = \sqrt{D} \cdot \sigma$

- (d) Für diesen Aufgabenteil sollen Sie wieder das Projekt-Repository aus dem letzten Semester verwenden. Nutzen Sie dieses, um einen Datensatz mit 10000 Ereignissen zu erstellen. Der Datensatz soll auch für spätere Aufgaben verwendet werden.

N_off Region: 220° bis 270°
N_on Region: 40° bis 90°

- Was passiert, wenn Sie die Untergrundregion stark vergrößern?
 - Die Signifikanz wird größer. Aber auch alpha wird größer.
- Was passiert bei einer höheren Anzahl von Ereignissen?
 - Die Signifikanz wird größer. Der Peak wird schmäler.
- Welches Problem sehen Sie, wenn man in der laufenden Analyse die Quellregion beliebig ändert?
 - Man sollte die Nullhypothese vor der Analyse aufstellen.
 - Wenn man die Region so wählt, dass die Signifikanz am größten wird, dann führt man einen Bias ein und die Analyse ist nicht mehr unvoreingenommen.



```
stats.py  x
project_a3 > stats.py > ...
1 import numpy as np
2
3
4 def significance(n_on, n_off, alpha):
5     """Calculate the significance of an observation.
6
7     Parameters
8     -----
9     n_on : int
10    | Count of events in On-Region.
11    n_off : int
12    | Count of events in Off-Region.
13    alpha : float
14    | Weighting of Off-Region.
15
16    Returns
17    -----
18    float
19    """
20
21    D = -2* ( (n_off + n_on)*np.log(n_off+n_on) - n_off*np.log(n_off) - n_on*np.log(n_on) + n_on*np.log(alpha) - (n_off+n_on)*np.log(1+alpha) )
22
23    return np.sqrt(D)
24
25
26 def test_significance():
```

```
Run Cell | Run Above | Debug Cell
# %%
import numpy as np
Run Cell | Run Above | Debug Cell
# %%
!python exercises/testen.py a3 {data_dir} -d {data_dir} \
--on-region {np.deg2rad(220)},{np.deg2rad(270)} \
--off-region {np.deg2rad(40)},{np.deg2rad(90)}
```

Aufgabe 38 Zwei Histogramme

Gegeben sind zwei Histogramme mit dem gleichen Binning (r Bins). Die Hypothese ist, dass beide Histogramme Zufallszahlen mit der gleichen Verteilung repräsentieren. Das heißt es existieren r Wahrscheinlichkeiten p_1, \dots, p_r dafür, dass eine Beobachtung im i -ten Bin liegt ($\sum_{i=1}^r p_i = 1$). Die Einträge im i -ten Bin des ersten Histogramm werden als n_i und im zweiten m_i bezeichnet. Die Anzahl der Beobachtungen im ersten Histogramm ist $N = \sum_{i=1}^r n_i$ und im zweiten $M = \sum_{i=1}^r m_i$.

- (a) Welcher Verteilung folgen die Zähleraten in den einzelnen Bins? Stellen sie die PDF für ein einzelnes Bin für beide Histogramme (n_i und m_i) unter Annahme der Nullhypothese auf.

$$\text{Es handelt sich um Zähleraten} \rightarrow \text{Poisson-Verteilung : } \text{PDF}(k) = \frac{\lambda^k}{k!} \exp(-\lambda)$$

$$\begin{aligned} \langle n_i \rangle &= p_i \cdot N \Rightarrow \text{PDF}(n_i) = \frac{1}{n_i!} \cdot \langle n_i \rangle^{n_i} \exp(-\langle n_i \rangle) \\ &= \frac{1}{n_i!} (p_i N)^{n_i} \exp(-p_i N) \quad \text{mit } \sum_{i=1}^r n_i \stackrel{!}{=} N \end{aligned}$$

analog

$$\langle m_i \rangle = p_i \cdot M \Rightarrow \text{PDF}(m_i) = \frac{1}{m_i!} (p_i M)^{m_i} \exp(-p_i M) \quad \text{mit } \sum_{i=1}^r m_i \stackrel{!}{=} M$$

- (b) Stellen sie die Likelihood Funktion für die Nullhypothese auf. Finden sie den Schätzer \hat{p}_i , der die Likelihood maximiert.

$$L(p_i | n_i, m_i) = \text{PDF}(n_i | p_i) \cdot \text{PDF}(m_i | p_i) = \text{PDF}(n_i) \cdot \text{PDF}(m_i)$$

$$\text{negative Log-Likelihood: } F(p_i) := -\ln(L(p_i | n_i, m_i)) = -\ln(\text{PDF}(n_i)) - \ln(\text{PDF}(m_i))$$

$$\begin{aligned} F(p_i) &= -\ln\left(\frac{1}{n_i!} (p_i N)^{n_i} \exp(-p_i N)\right) - \ln\left(\frac{1}{m_i!} (p_i M)^{m_i} \exp(-p_i M)\right) \\ &= -n_i (\ln(p_i) + p_i N + \ln(n_i!)) - n_i \ln(N) - m_i (\ln(p_i) + p_i M + \ln(m_i!)) - m_i \ln(M) \end{aligned}$$

minimiere:

$$\frac{\partial F}{\partial p_i} = -\frac{n_i}{p_i} + N - \frac{m_i}{p_i} + M \stackrel{!}{=} 0$$

$$\Leftrightarrow (N+M) p_i = n_i + m_i$$

$$\Leftrightarrow \hat{p}_i = \frac{n_i + m_i}{N + M}$$

- (c) Stellen sie die χ^2 -Test-Statistik unter Annahme der Nullhypothese auf. (Keine Vereinfachung des Terms nötig)

$$\chi^2 = \sum_{i=1}^r \frac{(n_i - \hat{n}_i)^2}{\hat{\text{Var}}(n_i)} + \frac{(m_i - \hat{m}_i)^2}{\hat{\text{Var}}(m_i)} \quad \hat{n}_i \triangleq \text{Schätzwert des Erwartungswert von } n_i;$$

$$\chi^2 = \sum_{i=1}^r \frac{(n_i - N \hat{p}_i)^2}{\hat{\text{Var}}(n_i)} + \frac{(m_i - M \hat{p}_i)^2}{\hat{\text{Var}}(m_i)}$$

$$\chi^2 = \sum_{i=1}^r \frac{(n_i - N\hat{p}_i)^2}{N\hat{p}_i} + \frac{(m_i - M\hat{p}_i)^2}{M\hat{p}_i}$$

$$\text{mit } \hat{p}_i = \frac{n_i + m_i}{N+M}$$

- (d) Wie viele Freiheitsgrade hat die χ^2 Verteilung? Folgt die Test-Statistik für kleine Bininhalte ($n_i, m_i < 10$) immer noch einer χ^2 -Verteilung? Falls nein, warum nicht?

$$\#\text{Freiheitsgrade} = \#\text{Messwerte} - (\#\text{unabhängige Parameter})$$

$$\#\text{unabhängige Parameter} = \#\text{Parameter} - \#\text{Bedingungen}$$

hier:

$$\#\text{Messwerte} = r$$

$$\#\text{Parameter} = r + 2 \quad (\text{wegen } p_i, N \text{ und } M)$$

$$\#\text{Bedingungen} = 3 \iff \sum_{i=1}^r n_i = N, \sum_{i=1}^r m_i = M, \sum_{i=1}^r p_i = 1$$

$$\Rightarrow \#\text{Freiheitsgrade} = r - (r+2-3)$$

$$= r + 1$$

Für kleine Bininhalte gilt nicht, dass

die Poisson-Verteilung annähernd einer Gauß-Verteilung entspricht.

Also folgt die Test-Statistik auch nicht einer χ^2 -Verteilung.

- (e) Gegeben sind die Histogramme: $\begin{array}{ccc|ccc} n_1 & n_2 & n_3 & m_1 & m_2 & m_3 \\ 111 & 188 & 333 & 15 & 36 & 30 \end{array}$

Es kann gezeigt werden, dass die Test-Statistik zu $\chi^2 = \frac{1}{NM} \sum_{i=1}^r \frac{(Nm_i - Mn_i)^2}{n_i + m_i}$ vereinfachen lässt.
Prüfen Sie, ob für die gegebenen Histogramme die Nullhypothese für $\alpha = 0.1, 0.05, 0.01$ verworfen wird.

Werte einsetzen

$$\Rightarrow \chi^2 \approx 8,429$$

$$\#\text{Freiheitsgrade} = r + 1 = 4$$

Wenn der berechnete Wert größer ist,

als der abgelesene Wert, wird

d.h. Nullhypothese abgelehnt.

Percentage Points of the Chi-Square Distribution

Degrees of Freedom	Probability of a larger value of χ^2								
	0.99	0.95	0.90	0.75	0.50	0.25	0.10	0.05	0.01
1	0.000	0.004	0.016	0.102	0.455	1.32	2.71	3.84	6.63
2	0.020	0.103	0.211	0.575	1.386	2.77	4.61	5.99	9.21
3	0.115	0.352	0.584	1.212	2.366	4.11	6.25	7.81	11.34
4	0.297	0.711	1.064	1.923	3.357	5.39	7.78	9.49	13.28
5	0.554	1.145	1.610	2.675	4.351	6.63	9.24	11.07	15.09
6	0.872	1.635	2.204	3.455	5.348	7.84	10.64	12.59	16.81
7	1.239	2.167	2.833	4.255	6.346	9.04	12.02	14.07	18.48
8	1.647	2.733	3.490	5.071	7.344	10.22	13.36	15.51	20.09
9	2.088	3.325	4.168	5.899	8.343	11.39	14.68	16.92	21.67
10	2.558	3.940	4.865	6.737	9.342	12.55	15.99	18.31	23.21
11	3.053	4.575	5.578	7.584	10.341	13.70	17.28	19.68	24.72
12	3.571	5.226	6.304	8.438	11.340	14.85	18.55	21.03	26.22
13	4.107	5.892	7.042	9.299	12.340	15.98	19.81	22.36	27.69
14	4.660	6.571	7.790	10.165	13.339	17.12	21.06	23.68	29.14
15	5.220	7.261	8.047	11.027	14.330	18.75	22.31	25.00	30.50

als der abgelesene Wert, wird
die Nullhypothese abgelehnt.

Werte ablesen:

12	3.571	5.226	6.304	8.438	11.340	14.85	18.55	21.03	26.22
13	4.107	5.892	7.042	9.299	12.340	15.98	19.81	22.36	27.69
14	4.660	6.571	7.790	10.165	13.339	17.12	21.06	23.68	29.14
15	5.229	7.261	8.547	11.037	14.339	18.25	22.31	25.00	30.58
16	5.812	7.962	9.312	11.912	15.338	19.37	23.54	26.30	32.00
17	6.408	8.672	10.085	12.792	16.338	20.49	24.77	27.59	33.41
18	7.015	9.390	10.865	13.675	17.338	21.60	25.99	28.87	34.80
19	7.633	10.117	11.651	14.562	18.338	22.72	27.20	30.14	36.19
20	8.260	10.851	12.443	15.452	19.337	23.83	28.41	31.41	37.57

$$\alpha = 0.1$$

$$\Rightarrow 7,78 < 8,429 \Rightarrow \text{Nullhypothese akzeptieren}$$

$$\alpha = 0.05$$

$$\Rightarrow 9,49 > 8,429 \Rightarrow \text{Nullhypothese ablehnen}$$

$$\alpha = 0.01$$

$$\Rightarrow 13.28 > 8,429 \Rightarrow \text{Nullhypothese ablehnen}$$